

Fase 4 — Avaliação do Uso das Tools pelo Agente

Documento operacional para validação reproduzível do comportamento do agente ao selecionar, executar e utilizar tools.

Campo	Valor
Fase	4 — Avaliação do Uso das Tools pelo Agente
Objetivo	Validar se o agente sabe utilizar corretamente uma tool no contexto em que ela foi disponibilizada.
Entrada	Tool aprovada nas Fases 2 e 3 + dataset de avaliação + ambiente do agente.
Saída	Relatório reproduzível com resultados, métricas, evidências, falhas e decisão de gate.
Status possíveis	PASS / FAIL / BLOCKED / WAIVED

Princípio central: a Fase 3 comprova que a tool é funcionalmente correta; a Fase 4 comprova que o agente sabe quando e como utilizá-la.

1. Objetivo e escopo

A Fase 4 avalia o comportamento do agente diante de solicitações reais ou representativas. O foco não é testar novamente a implementação da tool, mas verificar se o agente toma a decisão correta e executa o fluxo corretamente.

Fluxo avaliado

Etapa	O que deve ser validado
1. Solicitação	Interpretação da intenção do usuário.
2. Seleção	Tool correta, outra tool ou nenhuma tool.
3. Parâmetros	Argumentos corretos, completos e coerentes.
4. Execução	Chamada correta, quantidade e ordem de chamadas.
5. Resultado	Interpretação fiel do retorno.
6. Resposta	Resposta final consistente com o resultado e o contexto.

A fase contempla dez validações: seleção da tool; no-tool; desambiguação; construção dos parâmetros; execução; uso do resultado; cenários negativos; casos de fronteira; hard negatives; e end-to-end.

2. Pré-requisitos

- Tool aprovada na Fase 2 — Validação Técnica.
- Tool aprovada na Fase 3 — Validação Funcional.
- Contrato e documentação funcional atualizados.
- Dataset de avaliação versionado.
- Cenários esperados de uso e fronteiras funcionais conhecidos.
- Tools concorrentes ou semanticamente próximas identificadas.
- Ambiente de teste do agente disponível.
- Logs/traces capazes de registrar as decisões e tool calls.
- Mecanismo de captura da resposta da tool e da resposta final do agente.

3. Regras de execução

- Executar os cenários usando uma versão identificada do agente/modelo.
- Não alterar o cenário durante a execução sem registrar a alteração.
- Comparar o comportamento observado com o resultado esperado definido antes do teste.
- Registrar evidência suficiente para reproduzir o resultado.
- Não considerar somente a resposta final: tool, parâmetros, chamadas e resultado também fazem parte da avaliação.
- Problemas funcionais da própria tool devem ser encaminhados para as fases anteriores, quando aplicável.

4. Modelo de cenário de teste

Cada cenário deve ser identificável e conter expectativa explícita antes da execução.

Campo	Descrição
ID	Identificador único do cenário.
Categoria	Happy Path, Negative, Boundary, Hard Negative, No-Tool, Ambiguous ou variação de linguagem.
User Input	Solicitação enviada ao agente.
Intent	Intenção esperada.
Expected Tool	Tool esperada; pode ser NONE.
Expected Parameters	Parâmetros e valores esperados.
Expected Calls	Quantidade e ordem esperadas de chamadas.
Expected Behavior	Comportamento esperado do agente.
Expected Final Response	Resposta esperada ou critérios para avaliá-la.
Actual Tool	Tool efetivamente selecionada.
Actual Parameters	Parâmetros enviados.
Actual Result	Resultado efetivamente retornado.
Actual Response	Resposta final produzida.
Status	PASS / FAIL / BLOCKED / WAIVED.
Evidence	Trace, log, payload, screenshot, request/response ou referência.
Observation / Defect	Observações e referência de incidente, quando houver.

5. Validações

5.1 Seleção da Tool

O que validar: Validar se o agente identifica a intenção do usuário e seleciona a tool correspondente.

Como validar:

- Executar solicitações claras que tenham uma única tool esperada.
- Repetir a intenção com diferentes formulações de linguagem natural.
- Comparar a tool efetivamente selecionada com Expected Tool.
- Incluir casos em que outra tool é semanticamente próxima.

Critério de aceite: A tool correta é selecionada em todos os cenários aplicáveis; nenhuma tool inadequada é chamada.

Evidências: Input, intent esperada, tool esperada, tool efetiva, trace/log, versão do agente e status.

5.2 No-Tool

O que validar: Validar se o agente reconhece situações em que nenhuma tool é necessária.

Como validar:

- Executar perguntas que podem ser respondidas sem tool.
- Executar solicitações fora do domínio das tools.
- Executar casos em que faltam informações para uma chamada segura.
- Verificar se não ocorre chamada especulativa.

Critério de aceite: Quando Expected Tool = NONE, o agente não realiza chamada indevida e responde, esclarece ou recusa conforme comportamento definido.

Evidências: Input, lista de tool calls, trace, resposta final e status.

5.3 Desambiguação entre Tools

O que validar: Validar a diferenciação entre tools com funções semanticamente próximas.

Como validar:

- Criar pares/trincas de tools concorrentes.
- Executar uma solicitação para cada intenção.
- Executar variações de linguagem que removam termos óbvios.
- Registrar a característica que diferencia cada tool.

Critério de aceite: A tool escolhida corresponde à intenção funcional e respeita a fronteira definida para cada tool.

Evidências: Tool esperada, tools concorrentes, tool efetiva, input, motivo da distinção, trace e status.

5.4 Construção dos Parâmetros

O que validar: Validar se o agente extrai e monta corretamente os argumentos da chamada.

Como validar:

- Testar parâmetros obrigatórios.
- Testar opcionais e defaults.
- Testar tipos e formatos.
- Testar datas, filtros, IDs, quantidades e combinações.
- Comparar payload observado com Expected Parameters.

Critério de aceite: Todos os parâmetros enviados são corretos, necessários e compatíveis com o contrato da tool.

Evidências: Payload esperado e observado, contrato, trace/request, resposta e status.

5.5 Execução da Tool

O que validar: Validar se a chamada ocorre corretamente, sem chamadas desnecessárias.

Como validar:

- Comparar tool e payload executados com o esperado.
- Verificar quantidade de chamadas.
- Verificar ordem quando houver múltiplas chamadas.
- Identificar duplicidades ou chamadas especulativas.

Critério de aceite: A sequência de chamadas corresponde ao comportamento esperado para o cenário.

Evidências: Trace completo, lista de chamadas, timestamps, payloads, resultados e status.

5.6 Uso do Resultado

O que validar: Validar se o agente interpreta e utiliza corretamente o retorno da tool.

Como validar:

- Fornecer resultados conhecidos e verificáveis.
- Testar resultados únicos, múltiplos, vazios e parciais.

- Testar campos opcionais.
- Comparar a resposta final com o resultado efetivamente retornado.

Critério de aceite: A resposta é consistente com o retorno da tool, sem alteração indevida ou invenção de dados.

Evidências: Tool response, resposta final, trace e comparação expected/actual.

5.7 Cenários Negativos

O que validar: Validar o comportamento do agente diante de parâmetros inválidos, ausência de dados e erros.

Como validar:

- Parâmetro inválido.
- Parâmetro obrigatório ausente.
- Recurso inexistente.
- Resposta vazia.
- Erro da tool/API.
- Timeout ou indisponibilidade, quando suportado pelo ambiente.

Critério de aceite: O agente segue o comportamento definido: solicita informação, comunica impossibilidade ou trata o erro; não inventa parâmetros nem resultados.

Evidências: Input, erro/retorno da tool, comportamento observado, resposta final, trace e status.

5.8 Casos de Fronteira

O que validar: Validar se o agente preserva os limites funcionais estabelecidos na Fase 3.

Como validar:

- Reutilizar limites mínimo e máximo da Fase 3.
- Testar imediatamente abaixo do limite.
- Testar exatamente no limite.
- Testar imediatamente acima do limite.
- Testar limites de datas e valores, quando aplicável.

Critério de aceite: O agente respeita exatamente a regra funcional. Não ajusta, arredonda ou altera o input para contornar uma restrição, salvo comportamento explicitamente definido.

Evidências: Regra da Fase 3, input, parâmetros, chamada, resultado, resposta e status.

5.9 Hard Negatives

O que validar: Validar se o agente evita selecionar uma tool incorreta quando outra tool é funcionalmente adequada.

Como validar:

- Selecionar cenários plausíveis que se aproximem semanticamente da tool avaliada.
- Identificar a tool correta e a concorrente.
- Executar variações de linguagem.
- Verificar a fronteira funcional definida na Fase 3.

Critério de aceite: A tool correta é selecionada e a concorrente não é chamada indevidamente.

Evidências: Cenário, tool correta, tool concorrente, critério de diferenciação, tool efetiva, trace e status.

5.10 End-to-End

O que validar: Validar o fluxo completo desde a intenção até a resposta final.

Como validar:

- Executar o cenário como uma solicitação real.
- Validar intenção, seleção, parâmetros, execução, resultado e resposta.
- Considerar o cenário PASS somente quando todas as etapas aplicáveis estiverem corretas.

Critério de aceite: Todo o fluxo atende ao comportamento esperado. Uma resposta final correta não compensa uma execução incorreta.

Evidências: Trace completo, tool calls, payloads, resultados, resposta final e status.

6. Cenários de teste — exemplos

ID	Categoria	Input	Expected Tool	Expected Parameters	Aceite
TC-001	Happy Path	Qual é o saldo do cliente 123?	get_customer_balance	customer_id=123	Tool e parâmetro corretos.
TC-002	Happy Path	Quais foram as transações do cliente 123?	get_customer_transactions	customer_id=123	Não selecionar balance.
TC-003	No-Tool	O que significa saldo disponível?	NONE	—	Nenhuma tool.
TC-004	Negative	Consulte o saldo.	get_customer_balance ou esclarecimento	customer_id ausente	Não inventar ID.
TC-005	Boundary	Transações dos últimos 90 dias	get_customer_transactions	period=90	Aceitar se 90 for limite.
TC-006	Boundary	Transações dos últimos 91 dias	Definido pela F3	period=91	Respeitar limite; não truncar.
TC-007	Hard Negative	Quais foram as transações do cliente?	get_customer_transactions	customer_id conforme contexto	Não selecionar balance.
TC-008	Result Usage	Qual é o saldo do cliente 123?	get_customer_balance	customer_id=123	Resposta igual ao retorno da tool.

7. Formulário de execução

A tabela abaixo pode ser usada como registro operacional para cada cenário executado.

Campo	Preenchimento
Scenario ID	_____
Data/Hora	_____
Executor	_____
Dataset / versão	_____
Agente / versão	_____
Modelo	_____
User Input	_____
Intent esperada	_____
Tool esperada	_____
Tool executada	_____
Parâmetros esperados	_____
Parâmetros executados	_____
Resultado da tool	_____
Resposta final	_____
Status	PASS / FAIL / BLOCKED / WAIVED
Evidência / link	_____
Observações	_____
Defect / ticket	_____

8. Métricas

As métricas devem ser calculadas por dimensão e também segmentadas por categoria de cenário. Evite depender de uma única nota global.

Métrica	Definição
Tool Selection Accuracy	Seleções corretas / cenários que exigem tool.
Parameter Accuracy	Chamadas com parâmetros corretos / chamadas avaliadas.
No-Tool Accuracy	Decisões corretas de não chamar / cenários No-Tool.
Tool Call Accuracy	Execuções cuja tool, quantidade e sequência correspondem ao esperado.
Result Usage Accuracy	Respostas que utilizam corretamente o resultado da tool.
End-to-End Accuracy	Cenários em que todas as etapas aplicáveis estão corretas.

Segmentar pelo menos por: Happy Path, Negative, Boundary, Hard Negative, No-Tool e Ambiguous.

9. Evidências obrigatórias

Evidência	Obrigatoriedade	Objetivo
Input original	Obrigatória	Reproduzir o cenário.
Tool esperada	Obrigatória	Comparar decisão.
Tool efetiva	Obrigatória	Verificar seleção.
Parâmetros esperados/efetivos	Obrigatória	Verificar construção do payload.
Trace/log da execução	Obrigatória	Reconstituir o fluxo.
Tool response	Obrigatória quando houver chamada	Verificar uso do resultado.
Resposta final	Obrigatória	Verificar comportamento apresentado ao usuário.
Versão do agente/modelo	Obrigatória	Reprodutibilidade.
Status	Obrigatória	Consolidar resultado.
Ticket/defect	Quando houver FAIL	Rastreabilidade da correção.

10. Tratamento de falhas

Falha observada	Direcionamento inicial
Tool retorna resultado funcionalmente incorreto	Reavaliar Fase 3.
Tool/API indisponível ou comportamento técnico incorreto	Reavaliar Fase 2.
Agente seleciona tool incorreta	Fase 4 — seleção/desambiguação.
Parâmetro incorreto	Fase 4 — construção de parâmetros.
Chamada desnecessária	Fase 4 — No-Tool/execução.
Resultado correto, resposta final incorreta	Fase 4 — uso do resultado.
Agente inventa dados	Fase 4 — uso do resultado/negativos.

Para cada FAIL, registrar causa provável, evidência, severidade, ticket/defect e decisão sobre reteste.

11. Gate de aprovação

A aprovação deve considerar os resultados por dimensão, e não apenas uma média geral.

- Todos os cenários obrigatórios executados.
- Thresholds de acerto definidos pelo owner antes da execução.
- Seleção de tools dentro do threshold estabelecido.
- Parâmetros dentro do threshold estabelecido.
- No-Tool e hard negatives tratados corretamente.
- Limites funcionais da Fase 3 preservados.
- Uso dos resultados consistente com os retornos reais.
- Falhas críticas corrigidas ou formalmente aceitas pelo responsável.
- Evidências completas e reproduzíveis.

12. Resultado e entrega da Fase 4

Ao final da execução, gerar um relatório contendo:

- Identificação da versão do agente, modelo e dataset.
- Quantidade de cenários executados por categoria.
- Resultados por dimensão.
- Métricas de seleção, parâmetros, chamadas, No-Tool, resultado e End-to-End.
- Lista de FAILs e respectivos tickets.
- Hard negatives com maior taxa de erro.
- Casos de fronteira que apresentaram desvio.
- Decisão final: APPROVED / REJECTED / APPROVED WITH EXCEPTIONS.
- Exceções formalmente aprovadas, quando existirem.

13. Separação entre as fases

Fase	Pergunta principal	Envolve agente?
Fase 2 — Técnica	A tool funciona tecnicamente?	Não
Fase 3 — Funcional	A tool atende corretamente às regras do negócio?	Não
Fase 4 — Agente	O agente sabe quando e como usar a tool?	Sim

Saída final: um relatório reproduzível que demonstra, com evidências, se o agente utiliza corretamente a tool no contexto para o qual ela foi disponibilizada.